

FLASH NEIGA

# Dossier de pricing — Coach IA

Coût de l'intelligence artificielle (Google Gemini) : analyse complète, projections et leviers

Version 1.0 — Juillet 2026

Modèle de production : **Gemini 2.5 Flash** ( `gemini-flash-latest` )

Document interne — estimations de coûts fondées sur les tarifs officiels Google

# Sommaire

---

1. Résumé exécutif
2. Les fonctionnalités IA concernées
3. Modèle utilisé et tarifs officiels Gemini
4. Méthodologie : comment on estime les tokens
5. Coût par opération
6. L'économie du cache : coûts « one-shot » vs récurrents
7. Projections mensuelles à l'échelle
8. Profils d'usage détaillés
9. Tier gratuit vs payant & limites de débit
10. Leviers d'optimisation des coûts
11. Cadre business : coût rapporté au revenu
12. Risques & supervision
13. Recommandations
14. Annexes — hypothèses, glossaire, sources

**Périmètre.** Ce dossier chiffre le **coût de l'API Gemini** pour les fonctions de coaching IA de Flash Neiga (mini-leçons, bilans de série, chatbot, synthèse des questions pièges, discussions contextuelles). Il ne couvre pas l'hébergement (Render/Netlify), la base de données ni les autres coûts d'infrastructure, indépendants de l'IA.

# 1. Résumé exécutif

Le coach IA de Flash Neiga repose sur **Google Gemini 2.5 Flash**. Grâce à deux décisions techniques structurantes — **la mise en cache en base** des contenus générés et la **désactivation du « thinking »** — le coût de l'IA est très faible et largement prévisible.

**0,07–0,21 \$**

par élève actif / mois

**70–210 \$**

par mois pour 1 000 élèves

**< 2 %**

du revenu (accès vendu 10–30 €)

- **Trois des quatre fonctions sont mises en cache** et partagées entre tous les élèves : leur coût est essentiellement « one-shot » (payé une fois, réutilisé indéfiniment).
- **Le chatbot est le seul poste réellement proportionnel** au nombre d'élèves et à l'intensité d'usage — et il peut être divisé par ~5 en basculant sur Gemini 2.5 Flash-Lite.
- À l'échelle de **10 000 élèves actifs**, la facture reste de l'ordre de **700 à 2 100 \$/mois** selon l'intensité.
- Pour la production, il faut **lier une facturation (Tier 1)** et **fixer un plafond mensuel** ; le tier gratuit (~10 requêtes/min) ne tient pas la charge.

**Conclusion.** Le modèle économique est très sain : le coût IA est marginal face au revenu, et les principaux leviers d'optimisation sont *déjà* en place.

## 2. Les fonctionnalités IA concernées

Cinq usages de l'IA ont été intégrés au site. Chacun a un profil de coût différent selon qu'il est mis en cache ou non.

| Fonction                | Description                                                                                                            | Déclenchement                                                                                    | Cache                               |
|-------------------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|-------------------------------------|
| Mini-leçon              | Explication claire d'une erreur : pourquoi c'est faux, la règle du code israélien, les erreurs à éviter.               | Clic « Petite leçon » sur une réponse fausse (entraînement, examen, révision, questions pièges). | ✅ par (question + mauvaise réponse) |
| Bilan de série          | Bilan pédagogique de fin d'examen : notions maîtrisées / à retravailler, mini-cours par erreur, encouragement chiffré. | Fin d'un examen blanc.                                                                           | ✅ par examen                        |
| Chatbot « prof 24/24 »  | Conversation libre : l'élève pose ses questions, le prof répond en français.                                           | Bulle flottante présente sur tout le site.                                                       | ❌ conversation unique               |
| Discussion contextuelle | Chat intégré dans une leçon ou un cours, avec le contexte injecté (vrai suivi).                                        | Dans le dialog d'une mini-leçon et dans les cours.                                               | ❌ conversation unique               |
| Synthèse pièges         | Synthèse pédagogique des questions qui piègent le plus les élèves (tous confondus).                                    | Bouton admin, régénérable.                                                                       | ✅ une seule, régénérable            |

**Point clé d'architecture.** Le « thinking » de Gemini est **désactivé** ( `thinking_budget = 0` ) sur tous ces appels. Sans cela, un modèle 2.5 peut facturer 2 à 5× plus de tokens de sortie (réflexion invisible). C'est une économie majeure et silencieuse.

### 3. Modèle utilisé et tarifs officiels Gemini

Flash Neiga utilise `gemini-flash-latest`, alias de la dernière version stable de **Gemini 2.5 Flash**. Tarifs officiels Google (« Standard tier »), par **million de tokens** :

| Modèle                                     | Entrée / 1M | Sortie / 1M | Cache contexte / 1M |
|--------------------------------------------|-------------|-------------|---------------------|
| Gemini 2.5 Flash <span>notre modèle</span> | 0,30 \$     | 2,50 \$     | 0,03 \$             |
| Gemini 2.5 Flash-Lite                      | 0,10 \$     | 0,40 \$     | 0,01 \$             |
| Gemini 2.5 Pro (≤ 200k)                    | 1,25 \$     | 10,00 \$    | 0,125 \$            |

- **Mode Batch / Flex** : **-50 %** sur l'entrée et la sortie (pour les tâches non temps-réel).
- La **sortie coûte ~8× l'entrée** : c'est la longueur des réponses qui pilote le coût, pas la taille des prompts.
- On n'utilise pas le cache de contexte payant de Google : notre cache applicatif en base est plus adapté (voir §6).

Repère mémoire : 1 000 tokens d'entrée = 0,0003 \$ ; 1 000 tokens de sortie = 0,0025 \$.

## 4. Méthodologie : comment on estime les tokens

Un « token »  $\approx$  0,75 mot en français. Pour chaque opération, on additionne : le **prompt système** (consignes du prof), le **contenu envoyé** (question, options, historique...) et la **réponse générée**. Hypothèses retenues :

| Opération       | Entrée (tokens) | Sortie (tokens) | Base de l'estimation                                                  |
|-----------------|-----------------|-----------------|-----------------------------------------------------------------------|
| Mini-leçon      | ~520            | ~450            | Système ~120 + question/options/explication ~400 ; réponse ~230 mots. |
| Bilan de série  | ~1 300          | ~1 200          | ~6 erreurs détaillées + liste des cours ; réponse ~700 mots.          |
| Message de chat | ~800            | ~250            | Système ~180 + historique (plafonné 20 msg) ; réponse ~180 mots.      |
| Synthèse pièges | ~1 400          | ~800            | Top 30 questions listées ; réponse ~600 mots.                         |

**Ce sont des estimations.** Le coût réel varie avec la longueur effective des contenus. La §12 et l'annexe expliquent comment mesurer la consommation réelle ( `usage_metadata` renvoyé par chaque réponse Gemini).

## 5. Coût par opération

En appliquant les tarifs Gemini 2.5 Flash (0,30 \$ entrée / 2,50 \$ sortie) aux hypothèses ci-dessus :

| Opération       | Coût entrée | Coût sortie | Coût total  | Pour 1 \$ |
|-----------------|-------------|-------------|-------------|-----------|
| Mini-leçon      | 0,000156 \$ | 0,001125 \$ | ≈ 0,0013 \$ | ~770      |
| Bilan de série  | 0,00039 \$  | 0,0030 \$   | ≈ 0,0034 \$ | ~294      |
| Message de chat | 0,00024 \$  | 0,000625 \$ | ≈ 0,0009 \$ | ~1 150    |
| Synthèse pièges | 0,00042 \$  | 0,0020 \$   | ≈ 0,0024 \$ | ~415      |

Autrement dit : il faut environ **770 mini-leçons** ou **1 150 messages de chat** pour dépenser **1 seul dollar**.

## 6. L'économie du cache : coûts « one-shot » vs récurrents

Trois opérations sur quatre sont **mises en cache en base de données** et **réutilisées pour tous les élèves**. C'est ce qui rend le coût si bas.

### Mini-leçons — payées une fois, resservies à l'infini

Une leçon générée pour « question X + mauvaise réponse Y » ressort à *tous* les élèves qui commettront la même erreur. En régime établi, presque toutes les leçons sont déjà en cache : le **coût marginal tend vers zéro**.

Pré-générer **toutes** les combinaisons plausibles — par exemple 1 000 questions × ~3 mauvaises réponses fréquentes = **3 000 leçons** — coûterait **une seule fois**  $\approx 3\,000 \times 0,0013 \$ \approx 4 \$$ .  
Négligeable.

### Bilans de série & synthèse

Les bilans sont mis en cache par examen (jamais régénérés). La synthèse des questions pièges est une unique ligne en base, régénérée à la demande par l'admin (quelques centimes par régénération).

**À retenir** : le seul coût vraiment récurrent et proportionnel au nombre d'élèves, c'est le **chat** — car chaque conversation est unique et ne peut pas être mutualisée.



## 7. Projections mensuelles à l'échelle

Coût mensuel estimé selon le nombre d'élèves actifs et l'intensité d'usage (détail des profils en §8) :

| Élèves actifs / mois | Profil modéré (~0,07 \$/élève) | Profil intensif (~0,21 \$/élève) |
|----------------------|--------------------------------|----------------------------------|
| 100                  | ≈ 7 \$                         | ≈ 21 \$                          |
| 500                  | ≈ 35 \$                        | ≈ 105 \$                         |
| 1 000                | ≈ 70 \$                        | ≈ 210 \$                         |
| 5 000                | ≈ 350 \$                       | ≈ 1 050 \$                       |
| 10 000               | ≈ 700 \$                       | ≈ 2 100 \$                       |

### Coût mensuel — profil intensif (visualisation)

|        |  |          |
|--------|--|----------|
| 100    |  | 21 \$    |
| 500    |  | 105 \$   |
| 1 000  |  | 210 \$   |
| 5 000  |  | 1 050 \$ |
| 10 000 |  | 2 100 \$ |

+ un coût unique de pré-génération des leçons de l'ordre de quelques dollars, négligeable et non récurrent.

## 8. Profils d'usage détaillés

Les deux profils encadrent la réalité attendue. Détail du calcul par élève et par mois :

### Profil modéré — ≈ 0,07 \$ / élève / mois

| Poste                       | Volume | Coût unitaire | Sous-total |
|-----------------------------|--------|---------------|------------|
| Bilans de série (examens)   | 8      | 0,0034 \$     | 0,027 \$   |
| Messages de chat            | 40     | 0,0009 \$     | 0,036 \$   |
| Nouvelles leçons hors cache | 5      | 0,0013 \$     | 0,007 \$   |
| Total                       |        |               | ≈ 0,070 \$ |

### Profil intensif — ≈ 0,21 \$ / élève / mois

| Poste                       | Volume | Coût unitaire | Sous-total |
|-----------------------------|--------|---------------|------------|
| Bilans de série (examens)   | 15     | 0,0034 \$     | 0,051 \$   |
| Messages de chat            | 150    | 0,0009 \$     | 0,135 \$   |
| Nouvelles leçons hors cache | 15     | 0,0013 \$     | 0,020 \$   |
| Total                       |        |               | ≈ 0,206 \$ |

Le **chat représente ~50 à 65 %** du coût par élève. C'est le poste à surveiller — et le principal candidat à l'optimisation (voir §10).

## 9. Tier gratuit vs payant & limites de débit

### Tier gratuit (clé AI Studio, sans facturation)

Ordres de grandeur pour Gemini 2.5 Flash — à vérifier dans la console, Google ajuste par projet :

| Limite                  | Valeur indicative | Conséquence                                                         |
|-------------------------|-------------------|---------------------------------------------------------------------|
| Requêtes / minute (RPM) | ~10               | Au plus ~10 leçons/chats par minute, <i>tous élèves confondus</i> . |
| Requêtes / jour (RPD)   | ~1 500            | Plafond quotidien global.                                           |
| Tokens / minute (TPM)   | ~250 000          | Rarement limitant avant le RPM.                                     |

**Le tier gratuit ne tient pas la production.** À 10 requêtes/minute, une dizaine d'élèves qui cliquent « Petite leçon » ou discutent en même temps saturent le quota (erreurs 429). C'est acceptable pour tester, pas pour un usage réel.

### Tier 1 (facturation liée)

- Limites de débit bien supérieures, activation quasi instantanée.
- **Plafond de dépense par défaut : 250 \$/mois** (ajustable) — cohérent avec les projections jusqu'à plusieurs milliers d'élèves.
- Le code gère déjà proprement les dépassements : l'élève voit « le prof est momentanément indisponible » et **le reste du site continue de fonctionner**.

# 10. Leviers d'optimisation des coûts

Par ordre d'impact. Les trois premiers sont **déjà en place**.

| Levier                                   | Effet                                                                  | Statut     |
|------------------------------------------|------------------------------------------------------------------------|------------|
| Cache en base (leçons, bilans, synthèse) | Neutralise le coût des contenus répétés — le plus gros levier.         | ✓ en place |
| Thinking désactivé                       | Évite de payer des tokens de réflexion invisibles (2–5×).              | ✓ en place |
| Historique de chat plafonné (20 msg)     | Empêche le gonflement des prompts au fil de la conversation.           | ✓ en place |
| Chat sur Gemini 2.5 Flash-Lite           | ~5× moins cher sur le seul poste variable, qualité un cran en dessous. | option     |
| Mode Batch (~50 %) pour la synthèse      | Tâche non temps-réel → moitié prix.                                    | option     |
| Pré-génération des leçons (script)       | Lisse le coût, jamais ressenti par l'élève.                            | option     |
| Plafond de dépense + alerte budget       | Garde-fou anti-dérapage.                                               | recommandé |

## Impact du modèle sur le poste « chat » (1 000 élèves, profil intensif)

| Modèle du chat                       | Coût / message | Par élève / mois | 1 000 élèves |
|--------------------------------------|----------------|------------------|--------------|
| Gemini 2.5 Flash <span>actuel</span> | 0,0009 \$      | 0,135 \$         | ~135 \$      |
| Gemini 2.5 Flash-Lite                | ~0,0002 \$     | ~0,027 \$        | ~27 \$       |

|            |  |        |
|------------|--|--------|
| Flash      |  | 135 \$ |
| Flash-Lite |  | 27 \$  |

# 11. Cadre business : coût rapporté au revenu

Le coût IA par élève est à comparer au prix d'accès. Exemple pour un profil intensif (0,21 \$  $\approx$  0,19 € / élève / mois) :

| Prix d'accès (par élève) | Coût IA / élève | Part du revenu |
|--------------------------|-----------------|----------------|
| 10 €                     | ~0,19 €         | ~1,9 %         |
| 20 €                     | ~0,19 €         | ~1,0 %         |
| 30 €                     | ~0,19 €         | ~0,6 %         |

Même en usage intensif, l'IA pèse **~1–2 % du revenu au maximum**. Le coach IA est un argument de vente premium pour un coût quasi marginal.

Note : conversion indicative 1 \$  $\approx$  0,92 € (à ajuster selon le taux réel).

## 12. Risques & supervision

| Risque                            | Impact                                      | Parade (statut)                                           |
|-----------------------------------|---------------------------------------------|-----------------------------------------------------------|
| Saturation du débit (RPM) en pic  | Erreurs 429, IA indisponible ponctuellement | Tier 1 + limites relevées ; message propre côté élève ✓   |
| Dérapiage budgétaire (chat viral) | Facture qui grimpe                          | Plafond de dépense Google + alerte budget (à activer)     |
| Hausse des tarifs Google          | Coût unitaire ↑                             | Grille à re-vérifier ; possibilité de basculer de modèle  |
| Panne / indisponibilité API       | Fonctions IA KO                             | Le site reste fonctionnel, blocs IA en repli 503 ✓        |
| Estimations de tokens imprécises  | Écart budget prévu / réel                   | Logguer <code>usage_metadata</code> + suivi Cloud Billing |

**Mesurer le réel.** Chaque réponse Gemini renvoie `usage_metadata` (tokens entrée/sortie). Un compteur d'usage en base (table `ai_usage`) + un écran admin permettraient un suivi du coût au jour le jour. Cette instrumentation peut être ajoutée sur demande.

## 13. Recommandations

---

1. **Passer en Tier 1** (lier une facturation) avant la mise en production réelle.
2. **Fixer un plafond de dépense mensuel** (ex. 250 \$) et une **alerte budget**.
3. **Garder Gemini 2.5 Flash** pour les leçons et bilans (qualité), **envisager Flash-Lite pour le chat** si le volume de conversations devient important.
4. **Pré-générer les leçons** des questions les plus jouées via un script (confort + lissage).
5. **Activer un suivi de consommation** (logs `usage_metadata` ) pour piloter au réel.
6. **Ré-auditer les tarifs** tous les trimestres (Google fait évoluer sa grille).

**Synthèse en une phrase.** Grâce au cache en base et au thinking désactivé, le coach IA coûte de l'ordre de **0,07 à 0,21 \$ par élève actif / mois** sur Gemini 2.5 Flash ( $\approx 70$  à  $210$  \$/mois pour 1 000 élèves), le chat étant le seul poste vraiment variable — divisible par  $\sim 5$  sur Flash-Lite. Pour la prod : Tier 1 + plafond mensuel.

## 14. Annexes

---

### A. Hypothèses chiffrées

- Modèle : Gemini 2.5 Flash — entrée 0,30 \$/1M, sortie 2,50 \$/1M ; thinking désactivé.
- 1 token  $\approx$  0,75 mot (français). Tokens par opération : voir §4.
- Profil modéré : 8 bilans + 40 messages + 5 leçons neuves / élève / mois.
- Profil intensif : 15 bilans + 150 messages + 15 leçons neuves / élève / mois.
- Cache supposé « chaud » en régime établi (leçons/bilans/synthèse quasi jamais régénérés).
- Conversion indicative : 1 \$  $\approx$  0,92 €.

### B. Glossaire

- **Token** : unité de texte facturée (~0,75 mot en français).
- **Entrée / sortie** : ce qu'on envoie au modèle / ce qu'il génère.
- **RPM / RPD / TPM** : requêtes par minute / par jour, tokens par minute (limites de débit).
- **Thinking** : phase de raisonnement interne facturable, ici désactivée.
- **Cache applicatif** : stockage en base des contenus générés pour les réutiliser sans rappeler l'API.
- **Batch / Flex** : mode d'appel non temps-réel facturé -50 %.

### C. Sources

- Gemini API — Pricing : [ai.google.dev/gemini-api/docs/pricing](https://ai.google.dev/gemini-api/docs/pricing)
- Gemini API — Rate limits : [ai.google.dev/gemini-api/docs/rate-limits](https://ai.google.dev/gemini-api/docs/rate-limits)
- Analyses tierces du tier gratuit 2026 : [tokenmix.ai](https://tokenmix.ai), [aifreeapi.com](https://aifreeapi.com)